

Big Data Analytics

Attività – Data Analytics

Data processing e exploratory data analytics su dataset provenienti da più sorgenti

Obiettivo in breve: L'attività consiste nello sviluppare due progetti di Data Analytics in un ambito a proprio piacere e di proprio interesse, finalizzati allo storytelling, ovvero a trovare risposta a più quesiti di ricerca.

Quanti e quali dataset?

Il progetto deve partire da due (o più) dataset. Diversi siti Web, ad esempio

- <https://archive.ics.uci.edu/datasets>
- <https://www.kaggle.com/datasets>

consentono di scaricare dataset pubblici, è inoltre possibile effettuare lo scraping di dati pubblicati in pagine Web. Le pagine da dove è possibile scaricare i dataset ne forniscono una descrizione e, in alcuni casi, anche suggerimenti di quesiti che potrebbero essere indagati.

Descrizione:

Attività 1

- Scegliere un dataset orientato all'analisi di dati in formato tabulare.
- Usando PANDAS implementare le operazioni di data processing necessarie (principalmente join e selezioni) per preparare i dati per l'attività di data analytics. Verificare il contenuto ed indagarne l'integrità (dati sospetti, come vengono gestiti valori mancanti, etc ...)
- Usando pacchetti Python quali pandas, scipy, matplotlib, seaborn, sklearn, statsmodel, implementare step di data cleaning, exploratory data analysis e data visualization attraverso i quali sia possibile "raccontare il contenuto e le caratteristiche del dataset scelto" (storytelling), eventualmente partendo da dei quesiti di ricerca. L'uso dei pacchetti non deve necessariamente essere limitato alle istruzioni viste a lezione. Ricordo, tuttavia, che è buona norma essere a conoscenza del meccanismo di funzionamento degli strumenti di analisi utilizzati.
- Produrre un notebook Jupyter (<https://jupyter.org/>) che contenga:
 - Un'introduzione all'argomento scelto, alle sorgenti dati e agli obiettivi del progetto specificando i quesiti di ricerca o i motivi alla base della scelta del dataset.
 - Una sezione per ogni fase del progetto di data analytics. Ricordo che a lezione abbiamo affrontato argomenti quali: Data wrangling e cleaning con pandas; misure di centralità e dispersione; visualizzazione dei dati; correlazione tra variabili e misure di similarità; gestione ed imputazione di valori mancanti; outlier detection; feature rescaling e feature engineering, dimensionality reduction.

Si consideri che è altamente improbabile imbattersi in un dataset che si presti a tutte le analisi/manipolazioni viste durante le lezioni. Il fatto che alcuni argomenti non possano essere affrontati non costituisce un problema. Si precisa che la conoscenza di tutti gli argomenti, inclusi quelli non trattati nell'elaborato, potrebbe essere verificata in sede di esame orale.

Attività 2

- Scegliere un dataset relativo ad una serie temporale (si consiglia vivamente di cercare una serie semplice)
- Usando PANDAS implementare le eventuali operazioni di data preprocessing necessarie a rendere uniforme la frequenza di campionamento della serie e a gestire eventuali dati mancanti o outliers.
- Comprendere il significato della serie temporale ed individuare il comportamento di eventuali componenti sistematiche e non sistematiche della serie.
- Rendere la serie stazionaria e studiarne il correlogramma al fine di comprendere quale modello autoregressivo sia più adatto a fini previsionali.
- Applicare un metodo autoregressivo e valutare la bontà dei risultati.
- Produrre un notebook Jupyter (<https://jupyter.org/>) che contenga:
 - Introduzione e descrizione del dataset.
 - Una sezione per ogni fase del progetto di data analytics

Consegna: Upload dei notebook al corrispondente link nella pagina Moodle del corso.

Valutazione: Le attività verranno valutate sulla base dei seguenti criteri:

1. Motivazione. L'elaborato fa credere al lettore che l'argomento sia rilevante o importante (i) in generale e (ii) si adatti ad un tema di data science?
2. Comprensione/Storytelling. Dopo aver letto l'elaborato, un lettore non informato si sente informato sul tema? La parte in prosa dell'elaborato è convincente?
3. Codice. Il codice è ben scritto, ben documentato, riproducibile e aiuta il lettore a capire?
4. Tecnica. Le tecniche utilizzate riflettono una buona comprensione del fenomeno studiato ed una gestione attenta dei dati in esame. Ad esempio, le tecniche utilizzate sono motivate da osservazioni/considerazioni fondate o non vengono giustificate/si basano su ipotesi non veritiere?

Scadenza per premio partecipazione: **01/06/2026**